Nguyễn Hữu Đồng
2474802010087

III Thực hành

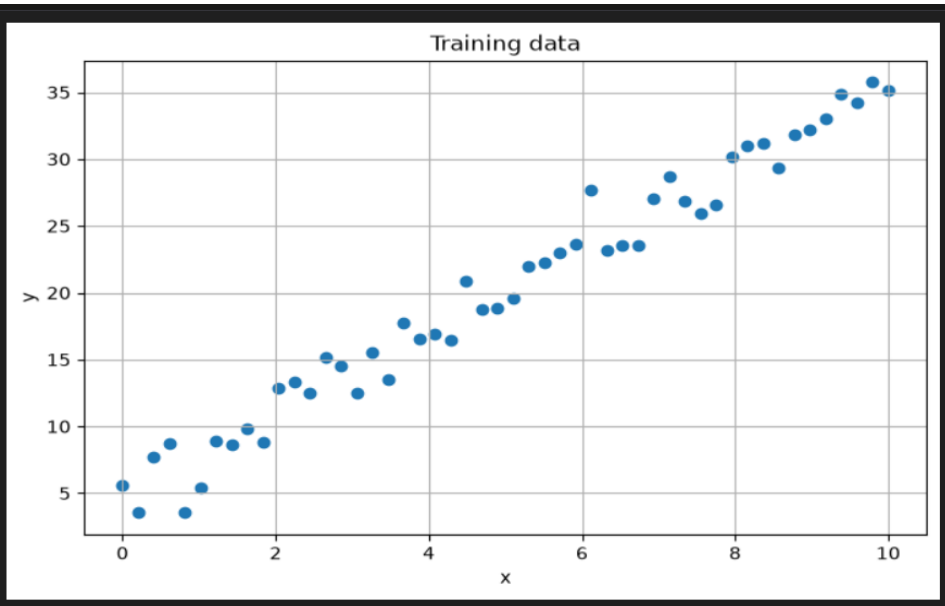
3.1

```
import numpy as np
import matplotlib.pyplot as plt
import time
from sklearn.linear_model import LinearRegression
from sklearn.metrics import mean_squared_error, r2_score

np.set_printoptions(precision=6, suppress=True)
```

[6] ✓ 7.2s

3.2



Nhận xét: Dữ liệu có xu hướng tuyến tính rõ ràng.
Nhiễu làm các điểm dữ liệu lệch khỏi đường y = 3x + 5, vì vậy w và b học được có thể không đúng chính xác 3 và 5.

3.3

[8] ✓ 0.0s

```
Initial MSE = 492.4133694116765
```

3.4

```
dw = -255.43443862559852
db = -40.36484412197205
```

Nguyễn Hữu Đồng
2474802010087

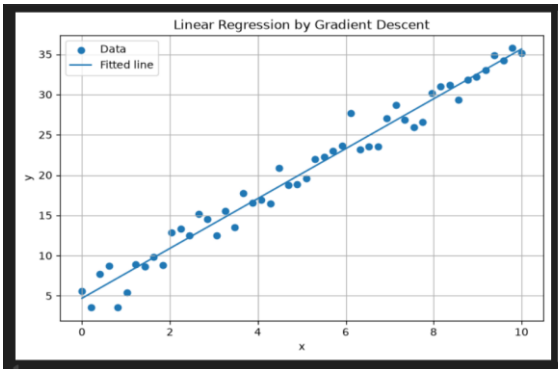
3.5

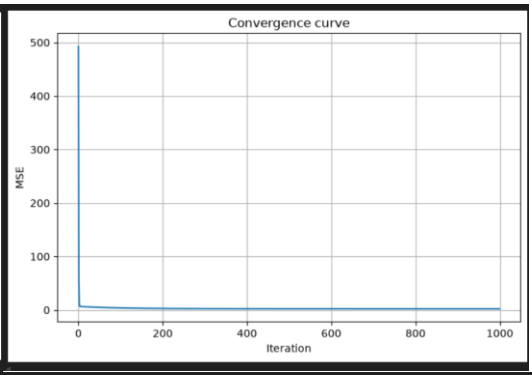
```
Đã cài đặt Batch Gradient Descent.
```

3.6

```
w = 3.09446474227027
b = 4.7033723560562315
epochs = 1000
runtime = 0.00944820000040636
final MSE = 2.242972046811748
```

3.7



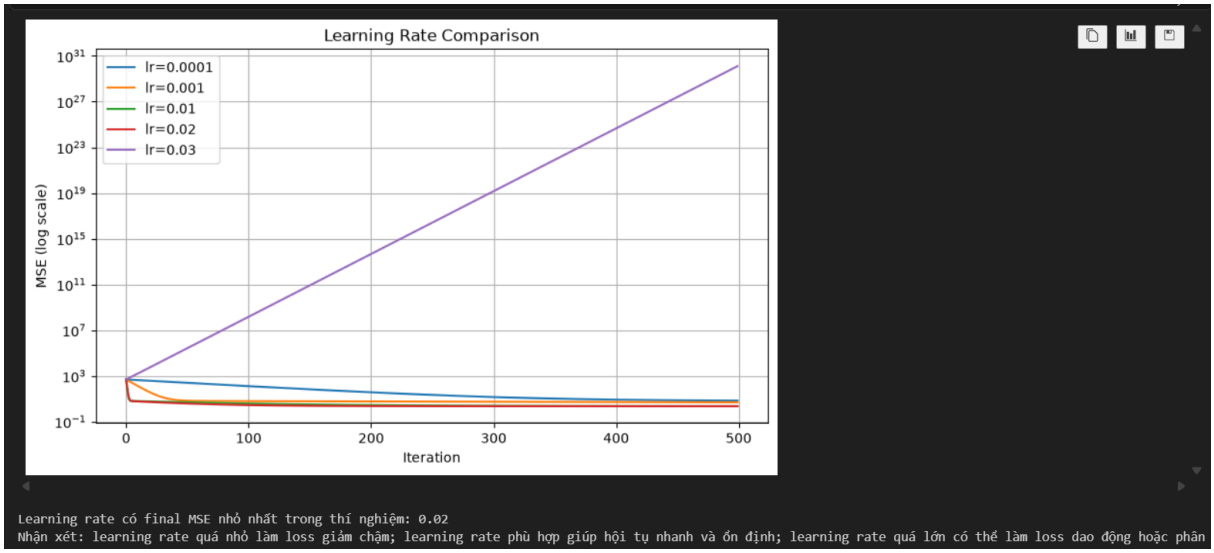



```
Nhận xét: Đường fitted line đi qua vùng trung tâm của dữ liệu.
Convergence curve giảm dần cho thấy Gradient Descent đang tiến về nghiệm tối ưu.
```

3.8

LR	w	b	Final MSE	Iter	Runtime	Status
0.0001	3.581967	0.642074	7.003778	500	0.005444	Hội tụ/ổn định
0.0010	3.575834	1.485756	4.957091	500	0.004604	Hội tụ/ổn định
0.0100	3.140410	4.396264	2.271783	500	0.005210	Hội tụ/ổn định
0.0200	3.094414	4.703713	2.242969	500	0.004632	Hội tụ/ổn định
0.0300	-201266020788834.500000	-30110269521272.859375	125616966159536541702265870745 6.000000			

Nguyễn Hữu Đồng
2474802010087



3.9

```
MSE = 2.2429701826717627
RMSE = 1.497654894383804
R2 = 0.9736379221621626
Nhận xét: R² cao cho thấy quan hệ tuyến tính được mô hình hóa khá tốt.
```

3.10

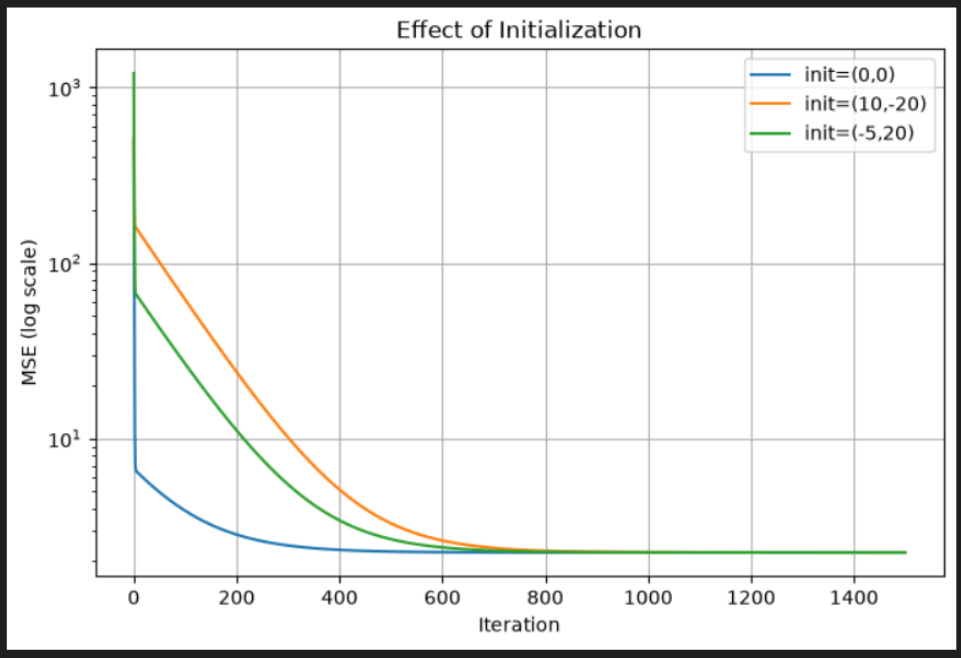
```
Phương pháp                  w          b          MSE          R²
Gradient Descent         3.094465   4.703372   2.242970   0.973638
scikit-learn             3.090471   4.730065   2.242787   0.973640

Nhận xét:
- Hai phương pháp thường cho w và b rất gần nhau.
- Nếu có chênh lệch, nguyên nhân chủ yếu là learning rate, số iteration hoặc tolerance của Gradient Descent.
- scikit-learn tìm nghiệm theo cách tối ưu được triển khai sẵn, còn phần chính của Lab tự cập nhật tham số bằng gradient.
```

3.11

Nguyễn Hữu Đồng
2474802010087

```
Init                w cuối      b cuối          MSE   Iterations
(0, 0)            3.090791    4.727931      2.242788         1500
(10, -20)           3.092399    4.717179       2.242830         1500
(-5, 20)            3.089238    4.738308       2.242804         1500
```




```
Nhận xét: Với learning rate ổn định, các nghiệm cuối thường rất gần nhau dù điểm khởi tạo khác nhau.
Điều này phù hợp với tính lồi của hàm MSE trong Linear Regression.
```

3.12

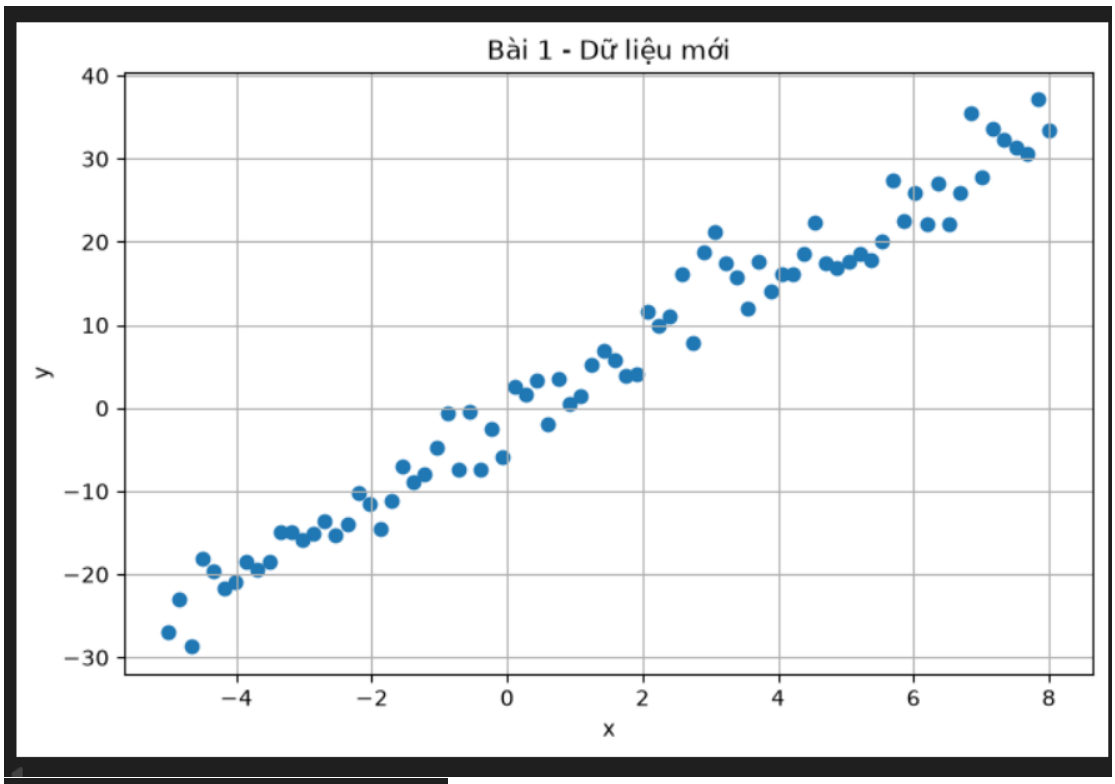
1 "w và b đóng vai trò là các biến tối ưu, bởi mục tiêu cốt lõi của thuật toán là xác định bộ tham số này sao cho giá trị MSE được tối thiểu hóa."
2 "Tốc độ học (learning rate) quá thấp khiến mức điều chỉnh w và b ở từng bước diễn ra rất chậm, do đó 500 vòng lặp có thể chưa đủ để mô hình chạm tới điểm tối ưu dù thuật toán vận hành chính xác."
3 "Mức η = 0.03 có khả năng đẩy hàm mất mát (loss) tăng vọt do bước nhảy quá lớn, làm thuật toán nhảy qua khỏi điểm tối ưu dẫn đến hiện tượng mất ổn định hoặc phân kỳ."
4 "Cả hai phương pháp đều hướng tới việc tìm w và b để giảm thiểu độ lệch. Trong khi Gradient Descent tối ưu hóa theo chu kỳ lặp dựa vào độ dốc, thì scikit-learn lại sử dụng công thức giải trực tiếp được tích hợp sẵn."
5 "Giá trị x quá lớn làm độ dài vector gradient theo w tăng mạnh, khiến việc ấn định tốc độ học trở nên phức tạp. Chuẩn hóa dữ liệu (feature scaling) giúp đưa các thuộc tính về cùng quy mô, hỗ trợ quá trình cập nhật diễn ra êm và ổn định hơn."

Nguyễn Hữu Đồng
2474802010087

6 "Trường hợp biểu đồ hội tụ biến động chập chờn, đi lên liên tục, không có dấu hiệu giảm hoặc trả về các giá trị bất thường (NaN/Inf), ta cần xem xét lại độ ổn định của tiến trình huấn luyện."

IV Bài tập

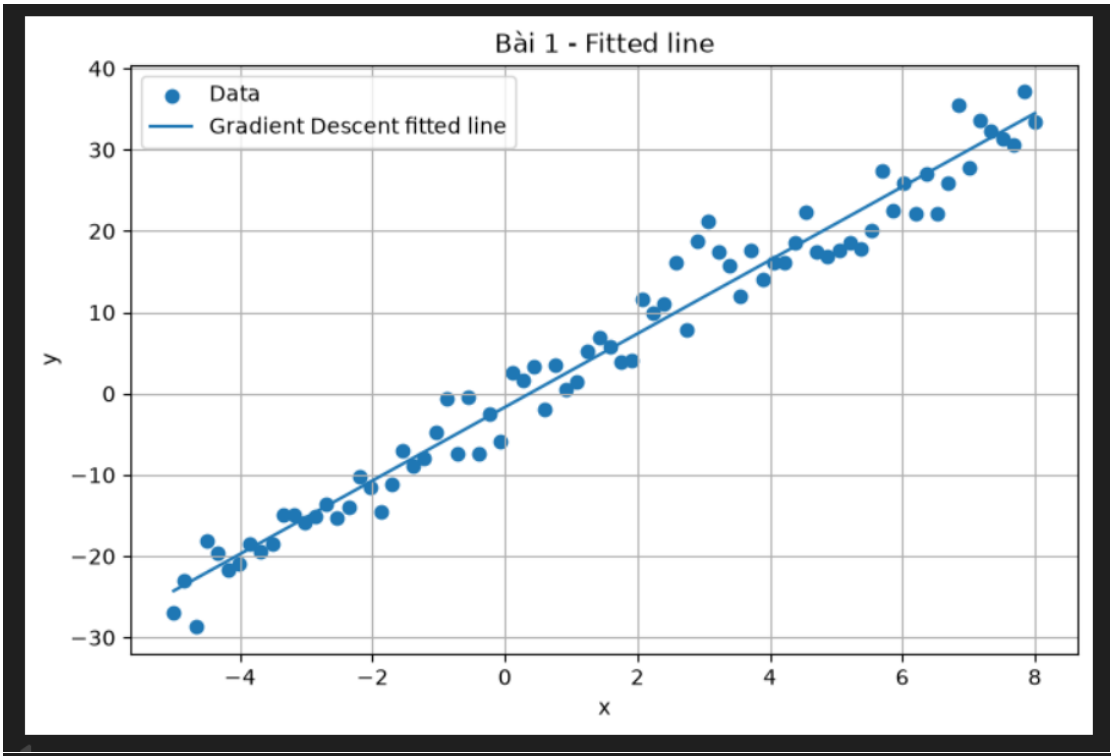
Bài 1

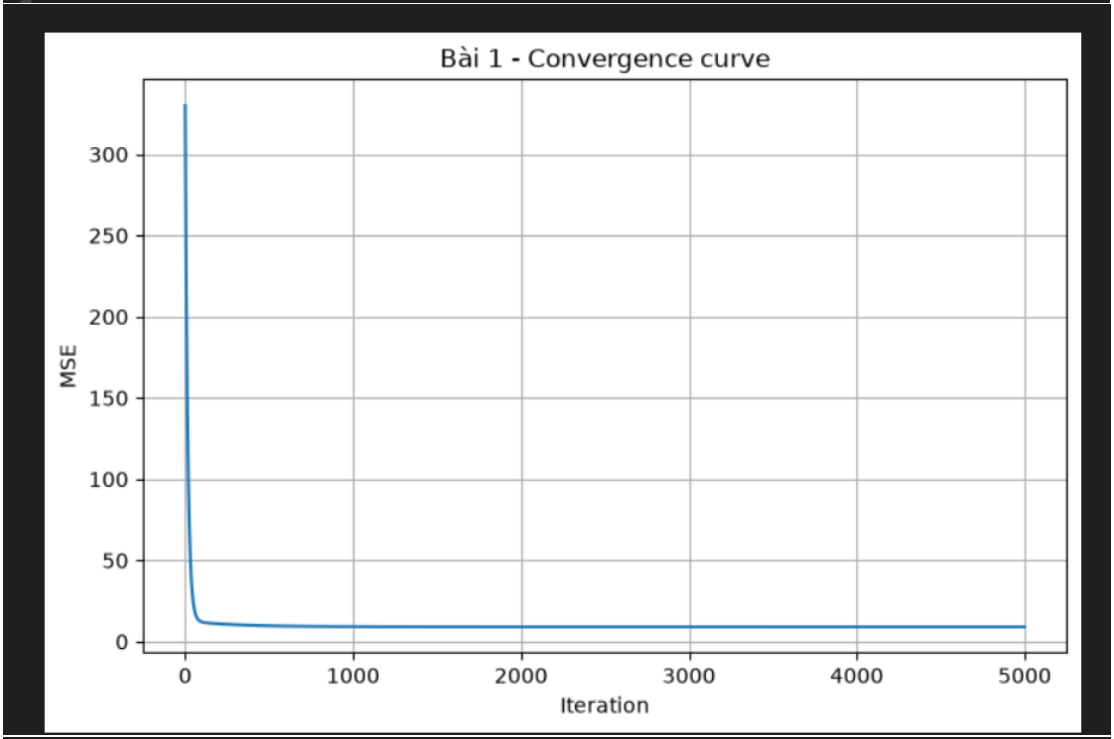



```
Gradient Descent:
w = 4.518017433665395
b = -1.6662325182248758
MSE = 9.07630465103331
RMSE = 3.012690599951032
R2 = 0.9701274959156716

scikit-learn:
w = 4.518054149700698
b = -1.6666200435119594
MSE = 9.076304521043568
R2 = 0.9701274963435019
```

Nguyễn Hữu Đồng
2474802010087





Nhận xét:
w̄ và b̄ không nhất thiết đúng chính xác 4.5 và -2 vì dữ liệu có nhiễu ngẫu nhiên.
Mô hình đang ước lượng quan hệ tốt nhất trên tập mẫu quan sát, không phải khôi phục chính xác từng tham số sinh dữ liệu.
Khi số mẫu tăng và nhiễu được xử lý tốt, nghiệm ước lượng thường có xu hướng gần tham số thật hơn.

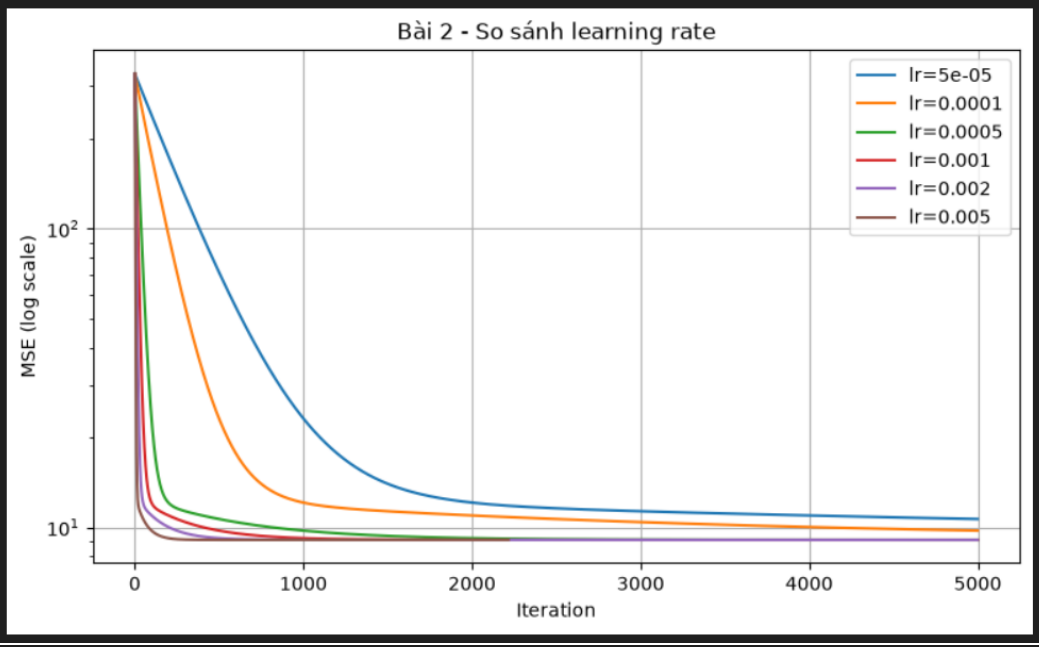
Nguyễn Hữu Đồng
2474802010087

Bài 2

0.2s

η	Iter	w	b	Final MSE	Runtime	Trạng thái
0.00005	5000	4.389020	-0.314817	10.658544	0.046834	Ổn định
0.00010	5000	4.434650	-0.786319	9.747302	0.048544	Ổn định
0.00050	5000	4.515362	-1.638204	9.077005	0.047854	Ổn định
0.00100	5000	4.518017	-1.666233	9.076305	0.047628	Ổn định
0.00200	5000	4.518054	-1.666620	9.076305	0.048720	Ổn định
0.00500	2217	4.518054	-1.666620	9.076305	0.021917	Ổn định

0.4s




```
Learning rate được chọn: 0.005
Lý do: final MSE thấp và đường convergence giảm ổn định.
Learning rate quá nhỏ cần nhiều iteration để tiến gần nghiệm.
Learning rate lớn hơn có thể hội tụ nhanh hơn nhưng nếu quá lớn sẽ gây dao động hoặc phân kỳ.
```

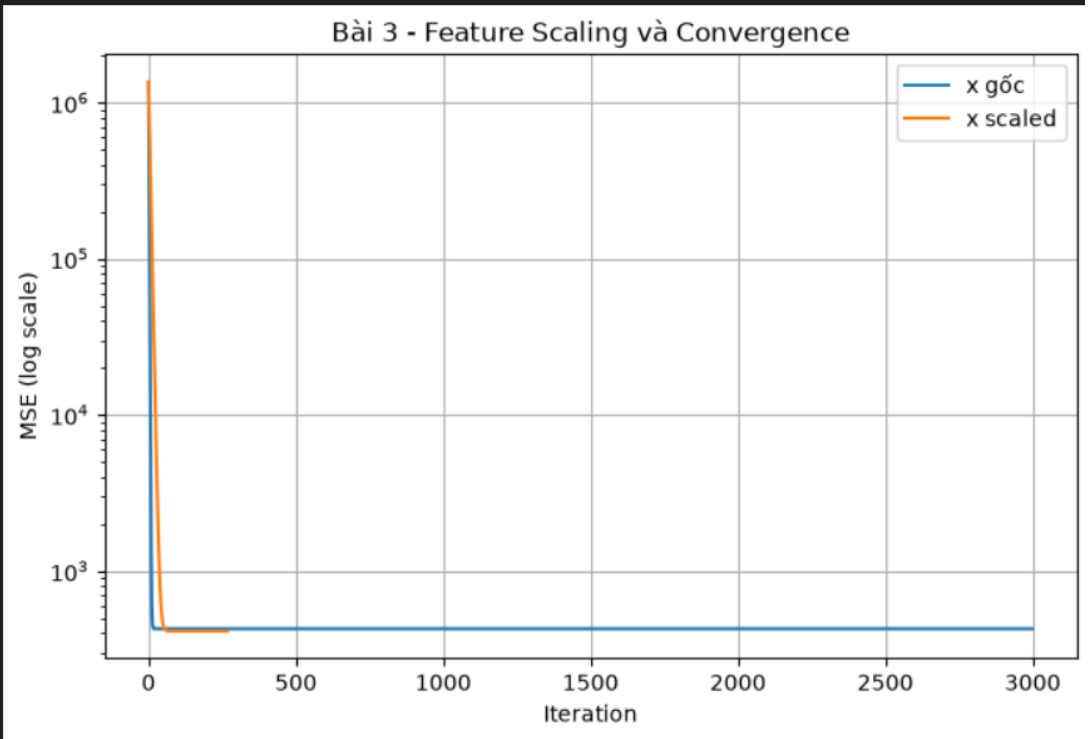
Nguyễn Hữu Đồng
2474802010087

Bài 3

```
0.2s

TRƯỜNG HỢP A - x gốc
lr = 1e-08 | MSE = 425.94107880721015 | w = 2.0088884515667713 | b = 0.0031098632904848064
lr = 5e-08 | MSE = 425.9393014519363 | w = 2.008887766480061 | b = 0.0035717650956545322
lr = 1e-07 | MSE = 425.93708006326204 | w = 2.0088869059196517 | b = 0.004149102652200345
lr = 5e-07 | MSE = 425.91932116427245 | w = 2.008880023802437 | b = 0.008766215757966824
lr = 1e-06 | MSE = 425.89715303704304 | w = 2.008871427068177 | b = 0.014533640692357063

TRƯỜNG HỢP B - x_scaled
lr = 0.001 | MSE = 419.6496259323758 | w_scaled = 582.4800664043499 | b = 1003.8923825648235
lr = 0.005 | MSE = 411.3983000454042 | w_scaled = 583.9187864978911 | b = 1006.371986976806
lr = 0.01 | MSE = 411.3983000454041 | w_scaled = 583.9187864997026 | b = 1006.3719869799281
lr = 0.02 | MSE = 411.39830004540437 | w_scaled = 583.918786500628 | b = 1006.3719869815228
lr = 0.05 | MSE = 411.39830004540454 | w_scaled = 583.9187865011827 | b = 1006.3719869824789
```



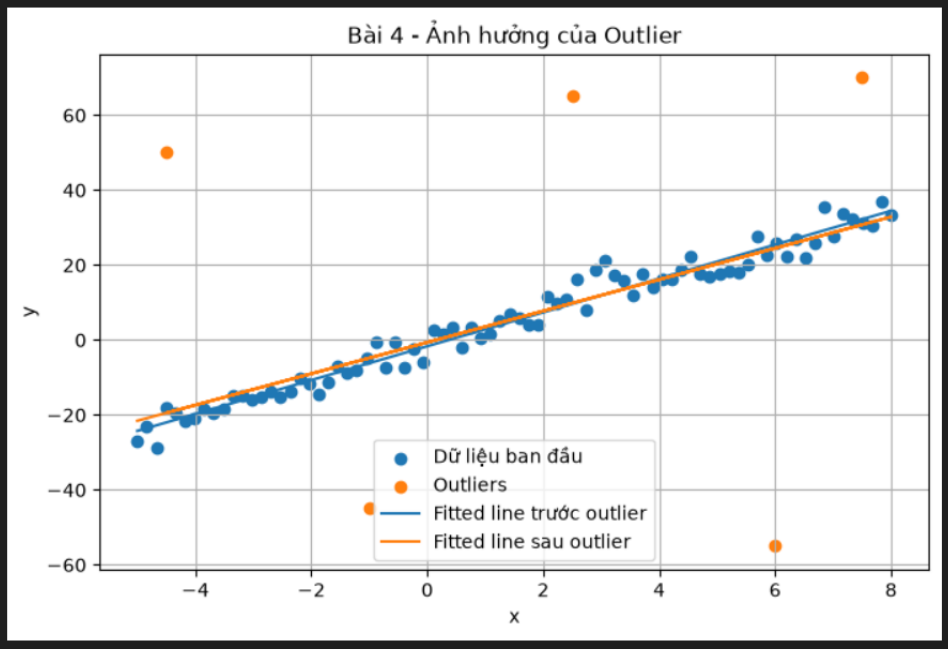

```
Nhận xét 5–8 dòng:
1. Khi x nằm trong khoảng 0 đến 1000, gradient theo w có thể có độ lớn lớn.
2. Vì vậy learning rate phải chọn nhỏ hơn để tránh cập nhật quá mạnh.
3. Sau khi chuẩn hóa x về z-score, độ lớn của feature được đưa về thang đo gần 1.
4. Gradient trở nên dễ kiểm soát hơn và việc chọn learning rate thường thuận lợi hơn.
5. Scaling giúp quá trình Gradient Descent ổn định và thường dễ hội tụ hơn.
6. Điều này đặc biệt quan trọng khi các feature có thang đo rất khác nhau.
7. Vì vậy feature scaling là bước hữu ích trong các thuật toán tối ưu dựa trên gradient.
```

Nguyễn Hữu Đồng
2474802010087

Bài 4

Chỉ số	Trước outlier	Sau outlier
MSE	9.076305	214.325500
RMSE	3.012691	14.639860
R^2	0.970127	0.546847

[26] ✓ 0.1s

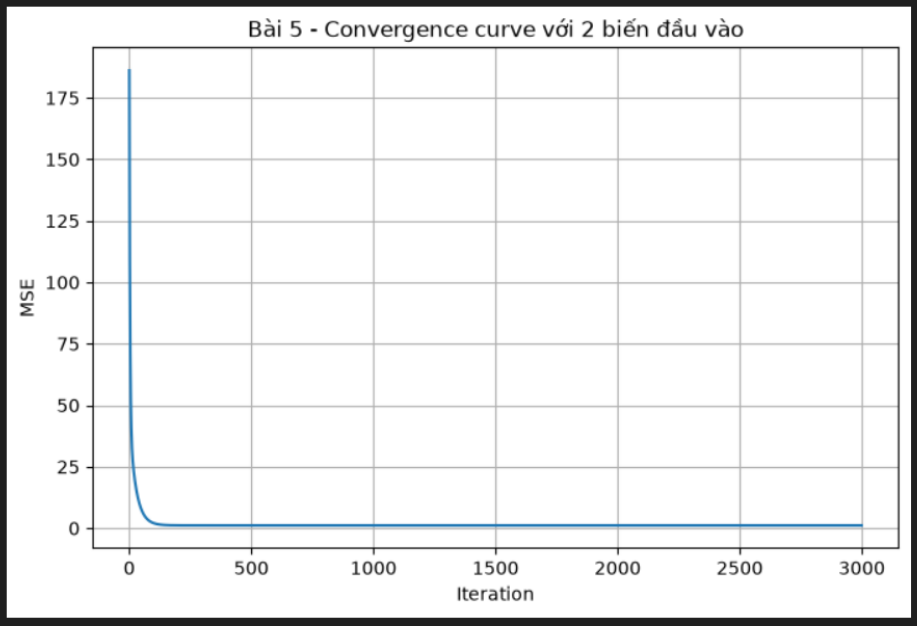


Nhận xét:
Outlier làm một số residual rất lớn.
Do MSE bình phương residual nên các điểm sai lệch lớn có ảnh hưởng rất mạnh đến loss.
Vì vậy fitted line có thể bị kéo về phía các outlier.
MSE và RMSE thường tăng rõ rệt; R^2 cũng có thể giảm.
Kết quả cho thấy Linear Regression dùng MSE khá nhạy với outlier.

Nguyễn Hữu Đồng
2474802010087

Bài 5

```
Kết quả Gradient Descent 2 biến:
w1 = 3.041598660470671
w2 = -2.0262786072240604
b  = 7.0237066473290986
MSE = 1.1388492519229012
RMSE = 1.067168801981627
R2 = 0.9896524051814335
```




```
Nhận xét:
Mô hình 2 biến học đồng thời ba tham số w1, w2 và b.
Khi loss giảm và R² cao, mô hình đã học được quan hệ giữa hai biến đầu vào và y.
Cách mở rộng này giữ nguyên nguyên lý của Batch Gradient Descent: tính gradient rồi cập nhật từng tham số.
Điểm khác là số lượng tham số tăng từ 2 lên 3.
```